

Évaluation hiérarchique des prédictions dans la taxonomie TIMEL

October 3, 2025

1 Introduction

Dans le cadre de l'évaluation d'un modèle de type VLM (Vision-Language Model) appliqué à la description d'enluminures, nous disposons d'une **taxonomie hiérarchique** TIMEL qui organise les concepts iconographiques en plusieurs niveaux (racine $\rightarrow$ catégories $\rightarrow$ sous-catégories $\rightarrow$ concepts spécifiques).

L'objectif n'est pas uniquement de vérifier si le modèle prédit *exactement* le bon label, mais aussi de *mesurer la proximité hiérarchique* entre la prédiction et la vérité terrain. Par exemple, prédire “poisson” à la place de “anguille” est une erreur moins grave que prédire “oiseau”.

Nous présentons ici un état de l'art sur les métriques de similarité hiérarchique, puis la spécificité de notre taxonomie et la métrique que nous proposons.

2 Définitions préliminaires

Soit $T = (V, E, r)$ une taxonomie représentée sous forme d'arbre enraciné, avec :

- V l'ensemble des nœuds (concepts),
- E l'ensemble des arêtes orientées (u, v) reliant un parent u à un enfant v ,
- $r \in V$ la racine de l'arbre.

Profondeur. La profondeur d'un nœud $c \in V$ est définie récursivement par :

$$\text{depth}(r) = 0, \quad \text{depth}(c) = 1 + \text{depth}(\text{parent}(c)).$$

Ancêtres. L'ensemble des ancêtres de $c \in V$ (incluant c et la racine) est :

$$\text{Anc}(c) = \{c, \text{parent}(c), \text{parent}^2(c), \dots, r\}.$$

Plus proche ancêtre commun (LCA). Le plus proche ancêtre commun de deux nœuds $a, b \in V$ est défini comme :

$$\text{LCA}(a, b) = \arg \max_{x \in \text{Anc}(a) \cap \text{Anc}(b)} \text{depth}(x).$$

Autrement dit, c'est l'ancêtre commun à a et b qui est le plus profond dans l'arbre.

3 Métriques path-based

Les métriques path-based exploitent uniquement la structure de l'arbre (profondeur et ancêtres).

3.1 Métriques classiques

Distances et similarités classiques

Distance d'arbre

$$d(a, b) = \text{depth}(a) + \text{depth}(b) - 2 \cdot \text{depth}(\text{LCA}(a, b)).$$

Wu & Palmer (1994)

$$\text{sim}_{WP}(a, b) = \frac{2 \cdot \text{depth}(\text{LCA}(a, b))}{\text{depth}(a) + \text{depth}(b)}.$$

Leacock & Chodorow (1998)

$$\text{sim}_{LC}(a, b) = -\log \frac{d(a, b)}{2D},$$

où D est la profondeur maximale de l'arbre.

4 Métriques IC-based

Ces métriques exploitent la distribution empirique des concepts dans un corpus annoté.

Information Content (IC)

$$IC(c) = -\log P(c),$$

où $P(c)$ est la probabilité d'occurrence de c (y compris ses descendants).

Resnik (1995)

$$\text{sim}_{Resnik}(a, b) = IC(\text{LCA}(a, b)).$$

Lin (1998)

$$\text{sim}_{Lin}(a, b) = \frac{2 \cdot IC(\text{LCA}(a, b))}{IC(a) + IC(b)}.$$

Jiang-Conrath (1997)

$$d_{JC}(a, b) = IC(a) + IC(b) - 2 \cdot IC(\text{LCA}(a, b)).$$

5 Spécificité de TIMEL

La taxonomie TIMEL est particulière par :

- la coexistence de **concepts concrets** (*casque, poisson*) et **concepts abstraits ou organisationnels** (*animal, objet liturgique*);
- une profondeur variable (concepts très généraux vs concepts très spécifiques comme *anguille*);
- une distribution empirique très déséquilibrée : certains concepts apparaissent massivement (*Vierge Marie*), d'autres presque pas.

6 Notre métrique proposée

Nous introduisons une métrique **similarité douce hiérarchique** :

$$\text{sim}_{soft}(a, b) = \frac{\text{depth}(\text{LCA}(a, b))}{\max(\text{depth}(a), \text{depth}(b))}.$$




Figure 1: Extrait hiérarchique de TIMEL avec proximités hiérarchiques (noir) et proximités fonctionnelles/thématiques (rouge pointillé).

Propriétés.

- $0 \leq \text{sim}_{\text{soft}}(a, b) \leq 1$.
- $\text{sim}_{\text{soft}}(a, a) = 1$.
- Si a et b ne partagent que la racine, $\text{sim}_{\text{soft}}(a, b) = 0$.
- Pour deux frères de profondeur d , $\text{sim}_{\text{soft}} = \frac{d-1}{d}$ (par ex. $d = 4 \Rightarrow 0.75$).

Exemples.

$$\text{sim}_{\text{soft}}(\text{anguille}, \text{saumon}) = 1.0, \quad \text{sim}_{\text{soft}}(\text{anguille}, \text{vache}) = 0.75, \quad \text{sim}_{\text{soft}}(\text{poisson}, \text{oiseau}) = 0.0.$$

7 IC dans TIMEL

Problèmes : classes rares, valeurs extrêmes, homogénéisation des scores. Nous utilisons un lissage additif ($\alpha = 1$) :

$$P(c) = \frac{\text{count}(c) + \alpha}{N + \alpha|V|}, \quad IC(c) = -\log P(c).$$

Exemple ($N = 9735$) :

$$\text{count}(\text{anguille}) = 10 \Rightarrow IC \approx 6.9, \quad \text{count}(\text{animal}) = 3000 \Rightarrow IC \approx 1.2.$$

7.1 Exemples comparatifs avec WuPalmer et Soft

Afin d'illustrer la comparaison, considérons un extrait réduit de la taxonomie TIMEL centré sur la classe *animaux* :




Figure 2: Extrait de la taxonomie TIMEL avec quelques concepts animaux et un objet.

Nous comparons la vérité terrain *anguille* avec plusieurs prédictions situées à différentes distances hiérarchiques :

GT	PR	Dist	WuPalmer	Soft
anguille	saumon	2	0.800	0.800
anguille	animaux aquatiques	1	0.667	0.750
anguille	vache	4	0.400	0.500
anguille	aigle	6	0.286	0.333
anguille	casque	8	0.000	0.000

Interprétation.

- **anguille–saumon** : deux frères sous *animaux aquatiques* → similarité élevée (0.8).
- **anguille–animaux aquatiques** : prédiction d'un ancêtre direct. WuPalmer reste modéré (0.667), mais **Soft** valorise mieux cette généralisation correcte (0.75).
- **anguille–vache** : appartiennent à des sous-catégories différentes (*aquatiques* vs *terrestres*) mais sous le même ancêtre *animaux* → similarité intermédiaire (0.4–0.5).
- **anguille–aigle** : ancêtre commun toujours *animaux*, mais branche plus éloignée → scores bas (≈ 0.3).
- **anguille–casque** : concepts disjoints (*Nature lieu* vs *Objets architecture*) → similarité nulle.

Pourquoi Soft est pertinent. WuPalmer mesure la proximité en fonction de la profondeur absolue de l'ancêtre commun. Cela pénalise fortement les cas où la prédiction est un **ancêtre exact mais plus général**. La métrique **Soft**, en normalisant par la profondeur du plus spécifique des deux concepts, atténue cette sévérité et attribue un score plus élevé lorsque le modèle saisit la bonne branche, mais avec un niveau de généralité supérieur.

Ainsi, *anguille–animaux aquatiques* n'est pas traité comme une erreur grave : Soft lui accorde 0.75, ce qui reflète une **erreur tolérable** par rapport à une confusion complète (ex. *anguille–casque*, score 0.0).

Différence entre WuPalmer et Soft. La différence clé entre WuPalmer et Soft réside dans la manière dont la profondeur est normalisée :

$$\text{sim}_{WP}(a, b) = \frac{2 \cdot \text{depth}(\text{LCA}(a, b))}{\text{depth}(a) + \text{depth}(b)}, \quad \text{sim}_{\text{soft}}(a, b) = \frac{\text{depth}(\text{LCA}(a, b))}{\max(\text{depth}(a), \text{depth}(b))}.$$

- **Cas “ancêtre direct” (anguille–animaux aquatiques).** - WuPalmer considère la profondeur absolue de l'ancêtre (*animaux aquatiques*), et divise par la somme des profondeurs. Cela aboutit à 0.667, comme si la prédiction était un “frère éloigné”. - Soft, au contraire, normalise par la profondeur du plus spécifique des deux concepts. Comme l'ancêtre est exactement le parent de la vérité terrain, Soft lui attribue 0.75, signalant que c'est une prédiction acceptable (bonne branche, mais moins précise).
- **Cas “cousins éloignés” (anguille–vache).** - L'ancêtre commun est *animaux*, situé deux niveaux au-dessus. - WuPalmer donne 0.400, Soft 0.500. Les deux reconnaissent une proximité, mais Soft est systématiquement un peu plus indulgent car il met en avant la part de hiérarchie partagée par rapport au niveau de granularité des concepts.
- **Cas “branche très différente” (anguille–aigle).** - L'ancêtre commun est toujours *animaux*, mais la distance est plus grande. - WuPalmer (0.286) chute plus vite, tandis que Soft (0.333) conserve un score légèrement supérieur.
- **Cas “branches disjointes” (anguille–casque).** - LCA = Racine, profondeur 0. - WuPalmer et Soft s'accordent : 0.0.

En résumé :

- WuPalmer est **stricte**, elle pénalise toute prédiction qui n'est pas très proche du label exact.
- Soft est **plus tolérante**, elle distingue mieux entre "prédiction générique mais correcte" (ancêtre direct) et "prédiction totalement erronée" (branche différente).

Cette différence justifie l'introduction de Soft : elle reflète mieux la logique d'évaluation dans TIMEL, où une prédiction plus générale est souvent moins grave qu'une confusion de branche.

8 Comparaison IC avec et sans lissage

GT	PR	Resnik _{smooth}	Lin _{smooth}	Resnik _{raw}	Lin _{raw}
phylactère	discussion	8.429	1.0	∞	—
bénédictin	moine	8.429	1.0	∞	—
crosse	bâton	8.429	1.0	∞	—
abbé	évêque	8.429	1.0	∞	—

Sans lissage : $IC = \infty$ pour les concepts absents $\rightarrow$ métriques inutilisables. Avec lissage : scores homogènes ($IC \approx 8.4$, $Lin=1$) $\rightarrow$ peu informatifs.

9 Conclusion

- Path-based : robustes mais structurelles uniquement. - IC-based : sensibles à la distribution, biaisés par la rareté. - Soft : simple, interprétable, reflète bien la proximité hiérarchique. - Une combinaison Soft + IC corrigé est une piste pour l'évaluation TIMEL.

10 Métriques de conformité JSON et taxonomique

En plus des métriques hiérarchiques, nous proposons d'évaluer la **validité des sorties JSON** produites par le modèle (conformité au format attendu et à la taxonomie TIMEL).

Soit N le nombre total de sorties (objets JSON) $\mathcal{O} = \{o_1, \dots, o_N\}$. Chaque sortie est censée avoir la forme :

$$o_i = \{\text{"timel-codes"} : [s_{i1}, \dots, s_{im_i}]\},$$

où chaque item s_{ij} doit être une chaîne de la forme

$$s_{ij} = \text{code} | \text{label}.$$

Soient $\mathcal{C}$ l'ensemble des codes de la taxonomie, $\mathcal{L}$ l'ensemble des labels, et $f : \mathcal{C} \rightarrow \mathcal{L}$ la correspondance définie par TIMEL.

10.1 JSON Error Rate (JER)

Proportion de sorties non parsables en JSON :

$$\delta_{\text{json}}(o_i) = \begin{cases} 1 & \text{si } o_i \text{ est un JSON invalide,} \\ 0 & \text{sinon,} \end{cases} \quad \text{JER} = \frac{1}{N} \sum_{i=1}^N \delta_{\text{json}}(o_i).$$

10.2 JSON Schema Error Rate (JSER)

Proportion de sorties parsables mais ne respectant pas le schéma attendu :

$$\delta_{\text{schema}}(o_i) = \begin{cases} 1 & \text{si } o_i \text{ est parsable mais invalide selon le schéma,} \\ 0 & \text{sinon,} \end{cases} \quad \text{JSER} = \frac{1}{N} \sum_{i=1}^N \delta_{\text{schema}}(o_i).$$

10.3 Taxonomy Error Rate (TER)

Parmi les sorties valides (parsables + schéma correct), proportion d'exemples contenant au moins une erreur taxonomique. Un item $s_{ij} = c|l$ est *valide* si

$$c \in \mathcal{C}, \quad l \in \mathcal{L}, \quad f(c) = l.$$

On note :

$$\delta_{\text{taxo}}(o_i) = \begin{cases} 1 & \text{si } \exists j \text{ tel que } s_{ij} \text{ est invalide,} \\ 0 & \text{sinon.} \end{cases}$$

Si N_{val} est le nombre de sorties valides, alors :

$$\text{TER} = \frac{1}{N_{\text{val}}} \sum_{i=1}^N \delta_{\text{taxo}}(o_i).$$

10.4 Taxonomy Error Rate micro (TER_micro)

Proportion d'items invalides sur l'ensemble des items :

$$M = \sum_{i=1}^{N_{\text{val}}} m_i, \quad M_{\text{err}} = \sum_{i=1}^{N_{\text{val}}} m_i^{\text{err}}, \quad \text{TER}_{\text{micro}} = \frac{M_{\text{err}}}{M}.$$

10.5 Taxonomy Error Rate macro (TER_macro)

Taux d'erreurs par sortie, moyenné sur les exemples valides :

$$\text{TER}_{\text{macro}} = \frac{1}{N_{\text{val}}} \sum_{i=1}^{N_{\text{val}}} \frac{m_i^{\text{err}}}{m_i}.$$

10.6 Exemple détaillé de calcul

Nous illustrons le calcul des métriques de conformité avec des sorties JSON produites par le modèle.

Exemples.

1. Exemple A (parsable mais taxonomiquement incorrect) :

```
{"timel-codes": ["tm-12345|Example Label", "tm-67890|Another Label"]}
```

Ici, les codes `tm-12345`, `tm-67890` n'appartiennent pas à la taxonomie TIMEL.

2. Exemple B (schéma invalide) :

```
{"wrong-key": []}
```

La clé attendue `"timel-codes"` est absente.

3. Exemple C (non parsable du tout) :

```
Not a JSON at all
```

4. Exemple D (parsable et conforme mais avec hallucination) :

```
{"timel-codes": ["tm-gpu9gq8p|anguille", "tm-12345|Wrong Label"]}
```

Le code `tm-gpu9gq8p` correspond bien à *anguille*, mais le second couple est incohérent.

Analyse.

- Exemple A : parsable, schéma OK, mais 2 items erronés $\Rightarrow$ ratio = 1.0.
- Exemple B : parsable mais schéma invalide $\Rightarrow$ compte pour JSER.
- Exemple C : non parsable $\Rightarrow$ compte pour JER.
- Exemple D : parsable, schéma OK, mais 1 item correct / 2 $\Rightarrow$ ratio = 0.5.

Résultats.

Ensemble	JER	JSER	TER	TER_micro	TER_macro
{A,B,C}	0.333	0.333	1.000	1.000	1.000
{D}	0.000	0.000	1.000	0.500	0.500

Lecture.

- Dans le premier ensemble {A,B,C}, un tiers des sorties sont non parsables (JER=0.333), un tiers sont mal formées (JSER=0.333), et toutes les sorties valides présentent des erreurs taxonomiques (TER=1.0). Comme tous les items sont erronés, on obtient TER_micro=TER_macro=1.0.
- Dans l'ensemble {D}, la sortie est conforme (JER=0, JSER=0), mais contient une hallucination taxonomique. Ainsi TER=1.0, et les scores TER_micro=TER_macro=0.5 reflètent que la moitié des items est correcte.